

Análisis Integral de Datos

Spotify Tracks Dataset

Regresión • PCA • Clustering • Red Neuronal

Curso: TC3002B — Implementación de Inteligencia Artificial

Institución: Tecnológico de Monterrey

Autores:

Valentino Villegas Martínez

Fecha: Junio 2025

Dataset: *Spotify Tracks Dataset* — Maharshi Pandya (Kaggle)
89,741 canciones • 114 géneros • 14 características de audio

Contents

1 Planteamiento del Problema y Contexto Estratégico 3

1.1 Descripción del Dataset 3

1.2 Objetivo del Proyecto 3

1.3 Valor Estratégico para Spotify 4

1.4 Limitación Importante 4

2 Regresión Lineal y Polinomial 4

2.1 Configuración Experimental 4

2.2 Modelos Evaluados 4

2.2.1 Regresión Lineal Múltiple (Baseline) 4

2.2.2 Regresión Polinomial con Ridge (Grado 3) 5

2.2.3 HistGradientBoosting Regressor (Modelo de referencia superior) 5

2.3 Tabla Comparativa de Desempeño 5

2.4 Análisis de Sobreajuste 5

2.5 Variables más Influyentes 5

2.6 Visualización: Comparación de Errores 6

3 Análisis de Componentes Principales (PCA) 7

3.1 Preparación de Datos 7

3.2 Varianza Explicada por Componente 7

3.3 Representación Visual: Curva de Varianza Acumulada 8

3.4 Variables más Influyentes por Componente 8

3.5 ¿Qué Variables Dominan la Estructura del Dataset? 8

4 Agrupamiento (Clustering) 9

4.1 Justificación del Algoritmo: K-Means 9

4.2 Selección del Número de Clusters 9

4.3 Perfil de los Clusters 10

4.4 Visualización de Clusters 10

4.5 Interpretación de Segmentos e Implicaciones Estratégicas 10

5 Clasificación con Red Neuronal 11

5.1 Formulación del Problema 11

5.2 División Train / Validation / Test 11

5.3 Preprocesamiento 11

5.4 Arquitectura del Modelo 12

5.5 Hiperparámetros y Mejoras Aplicadas 12

5.6 Métricas de Desempeño 13

5.7 Matriz de Confusión 13

5.8 Análisis de Errores por Clase 13

5.9 Riesgo de Sobreajuste 14

6 Conclusiones Estratégicas 14

6.1 Síntesis de Hallazgos 14

6.2 Respuesta a la Pregunta de Negocio 14

6.3 Próximos Pasos Recomendados 15

Referencias

16

1 Planteamiento del Problema y Contexto Estratégico

1.1 Descripción del Dataset

El dataset utilizado es el *Spotify Tracks Dataset* de Kaggle (Maharshi Pandya, 2023). Contiene **89,741 canciones** con la siguiente información por pista:

- **Metadatos:** identificador, artista, álbum, nombre, indicador de contenido explícito.
- **Variable objetivo:** *popularity* (0–100), calculada por Spotify en función del volumen y recencia de reproducciones.
- **10 características de audio:** *danceability*, *energy*, *loudness*, *speechiness*, *acousticness*, *instrumentalness*, *liveness*, *valence*, *tempo* y *key/mode/time_signature* (parámetros armónicos).
- **Género:** *track_genre* — 114 géneros únicos.

Para el módulo de clasificación, la variable continua *popularity* se discretizó en tres clases con los siguientes umbrales:

Table 1: Distribución de clases de popularidad

Clase	Rango de popularidad	Canciones
High	> 60 puntos	29,870 (33.3 %)
Medium	30–60 puntos	28,212 (31.4 %)
Low	< 30 puntos	31,659 (35.3 %)
Total		89,741 (100 %)

1.2 Objetivo del Proyecto

Determinar si las características de audio de una canción explican o predicen su popularidad en Spotify, y si el catálogo puede resumirse en grupos interpretables. El análisis cubre cuatro módulos:

1. **Regresión** — cuantificar la relación entre features de audio y popularidad continua.
2. **PCA** — identificar qué combinaciones de variables explican la mayor varianza y evaluar si se puede reducir dimensionalidad sin pérdida relevante.
3. **Clustering** — descubrir segmentos naturales del catálogo para orientar estrategias de playlist y recomendación.
4. **Red neuronal** — clasificar canciones en categorías de popularidad con el mayor desempeño posible.

1.3 Valor Estratégico para Spotify

Table 2: Alineación entre módulos analíticos y decisiones de negocio

Módulo	Pregunta de negocio	Aplicación estratégica
Regresión	¿Qué features predicen popularidad?	Orientar producción musical y A&R
PCA	¿Cuántas dimensiones reales existen?	Simplificar dashboards y motores de recomendación
Clustering	¿Qué tipos de canciones existen?	Diseño de playlists y perfilado de gustos
Red neuronal	¿En qué categoría cae esta canción?	Priorizar tracks para promoción y pruebas de playlist

1.4 Limitación Importante

La popularidad en Spotify está influenciada por factores externos al audio: reputación del artista, ubicación en playlists editoriales, momento del lanzamiento, marketing y tendencias sociales. Estos factores *no* están representados en el dataset. Los modelos deben tratarse como señales de apoyo a decisiones, no como pronósticos exactos de éxito comercial.

2 Regresión Lineal y Polinomial

2.1 Configuración Experimental

- **Observaciones totales:** 89,741 canciones.
- **División:** 80 % entrenamiento (71,792) / 20 % prueba (17,949).
- **Features numéricas (14):** `duration_min`, `is_explicit`, `danceability`, `energy`, `key`, `loudness`, `mode`, `speechiness`, `acousticness`, `instrumentalness`, `liveness`, `valence`, `tempo`, `time_signature`.
- **Feature categórica (1):** `track_genre` (114 géneros), codificada con *One-Hot Encoding*.
- **Métrica principal:** Error Cuadrático Medio (MSE).

2.2 Modelos Evaluados

Se evaluaron tres modelos en orden creciente de complejidad.

2.2.1 Regresión Lineal Múltiple (Baseline)

Modelo estándar sin regularización que establece el nivel de referencia. Ajusta un hiperplano en el espacio de features minimizando el MSE. Su sencillez lo hace altamente interpretable: cada coeficiente indica cuánto cambia la popularidad esperada al incrementar en 1 unidad la feature correspondiente.

2.2.2 Regresión Polinomial con Ridge (Grado 3)

Se exploraron grados 2 y 3. El **grado 3 con regularización Ridge** ($\alpha = 0.1$) ofreció la mejor relación bias-varianza. La regularización es necesaria porque la transformación polinomial aumenta el número de features de 14 a varios cientos, elevando el riesgo de sobreajuste sin restricciones.

2.2.3 HistGradientBoosting Regressor (Modelo de referencia superior)

Gradient boosting con tasa de aprendizaje 0.08, 250 iteraciones máximas, máximo 31 nodos hoja y regularización $L2 = 0.1$. Se incluye como techo de desempeño: captura relaciones no lineales sin transformación manual de features.

2.3 Tabla Comparativa de Desempeño

Table 3: Comparación de modelos de regresión

Modelo	MSE Train	MSE Test	RMSE Test	Brecha
Lineal Múltiple (baseline)	283.706	283.750	16.845	0.044
Polinomial Grado 3 + Ridge	275.662	281.250	16.771	5.588
HistGradientBoosting	226.335	251.406	15.856	25.071

2.4 Análisis de Sobreajuste

Table 4: Diagnóstico de sobreajuste por modelo

Modelo	Brecha MSE	Diagnóstico
Lineal Múltiple	0.044	Sin sobreajuste. La brecha casi nula indica <i>underfitting</i> : el modelo no captura la complejidad real del problema.
Polinomial G3 + Ridge	5.588	Sobreajuste leve. Ridge controla efectivamente la varianza introducida por las features polinomiales.
HistGradientBoosting	25.071	Sobreajuste moderado. La brecha es notable pero el MSE de prueba es el más bajo, lo que justifica su uso cuando la generalización es aceptable.

2.5 Variables más Influyentes

Los coeficientes de mayor valor absoluto en la regresión lineal corresponden a géneros musicales, confirmando que el género es el predictor dominante:

Table 5: Top 5 variables por coeficiente (regresión lineal)

Variable (género)	Coeficiente
Iranian	−38.738
Romance	−37.451
Latin	−32.462
Jazz	−31.473
Detroit-Techno	−31.190

Los coeficientes negativos de gran magnitud indican géneros con popularidad sistemáticamente baja. El signo negativo surge porque la codificación *one-hot* del género base (acústico) actúa como referencia positiva, y estos géneros tienen una popularidad promedio significativamente menor.

2.6 Visualización: Comparación de Errores




Figure 1: MSE sobre el conjunto de prueba por modelo. La regresión polinomial con Ridge mejora marginalmente el baseline ($\Delta\text{MSE} = 2.5$). El HistGradientBoosting representa una mejora del 11.4 % sobre el baseline.

Conclusión Ejecutiva

Los modelos de regresión muestran que las características de audio tienen poder predictivo **limitado pero consistente**. El mejor modelo lineal obtiene $\text{RMSE} \approx 16.8$ puntos en una escala de 0–100, equivalente a un error promedio de ± 16.8 puntos de popularidad. El género musical es el predictor dominante, lo que sugiere que la posición de una canción dentro de su nicho de mercado importa más que sus características acústicas internas. Para predicciones más precisas se recomienda incorporar datos de artista, historial de reproducciones y contexto editorial.

3 Análisis de Componentes Principales (PCA)

3.1 Preparación de Datos

- 1. **Selección de features:** 14 variables numéricas (se excluyen identificadores y variable objetivo).
- 2. **Estandarización:** cada variable se transforma a media 0 y desviación estándar 1 mediante `StandardScaler`. Paso obligatorio en PCA para evitar que variables con mayor escala (`loudness` en dB, `tempo` en BPM) dominen artificialmente los componentes.
- 3. **Tamaño:** 89,741 observaciones × 14 features.

3.2 Varianza Explicada por Componente

Table 6: Varianza explicada y acumulada por componente principal

Componente	Varianza individual (%)	Varianza acumulada (%)
PC1	17.1	17.1
PC2	12.8	29.9
PC3	10.2	40.1
PC4	8.9	49.0
PC5	8.1	57.1
PC6	7.6	64.7
PC7	6.8	71.5
PC8	6.2	77.7
PC9	5.7	83.4
PC10	5.3	88.7
PC11	4.8	≥90%: 93.5
PC12	3.3	96.8
PC13	2.1	98.9
PC14	1.1	100.0

Resultado clave: Se requieren **11 de 14 componentes** para superar el umbral del 90 % de varianza acumulada (93.5 % con 11 componentes). La reducción máxima sin sacrificar información es de solo 3 dimensiones (21.4 %).

3.3 Representación Visual: Curva de Varianza Acumulada




Figure 2: Varianza acumulada de los 14 componentes principales. La línea discontinua roja marca el umbral del 90 %. El punto destacado en rojo (PC11) es donde se supera ese umbral.

3.4 Variables más Influyentes por Componente

Table 7: Variables dominantes (*loadings*) por componente principal

PC	Variables dominantes	Interpretación
PC1	loudness, energy, acousticness, valence, instrumentalness	Intensidad sonora: energéticas/ruidosas o acústicas/instrumentales suaves.
PC2	valence, danceability, duration_min, acousticness, instrumentalness	Ritmicidad emocional: emociones positivas frecuentes y positivas frecuentes de larga duración.
PC3	speechiness, liveness, is_explicit, valence, danceability	Contenido vocal/vivo: rap/podcast de música instrumental.
PC4	mode, key, danceability, liveness, instrumentalness	Dimensión armónica: mayor/menor y su claridad.
PC5	key, is_explicit, time_signature, liveness, instrumentalness	Producción en vivo: de grabación y composición.

3.5 ¿Qué Variables Dominan la Estructura del Dataset?

Las variables `loudness`, `energy` y `acousticness` son las más influyentes: aparecen en múltiples componentes y tienen loadings de alta magnitud. Estas tres features están altamente correlacionadas de forma inversa (canciones energéticas suelen ser ruidosas y no acústicas), lo que explica por qué PC1 captura el 17.1 % de la varianza solo. La `valence` (positividad emocional) es transversal a varios componentes, confirmando que la emoción musical es multidimensional.

Conclusión Ejecutiva

El PCA revela que el espacio de audio de Spotify **no es altamente compresible**: se necesitan 11 de 14 dimensiones para preservar el 90 % de la información, lo que indica que las features capturan aspectos musicales genuinamente distintos (intensidad, ritmo, emoción, armonía, producción). Para dashboards operativos se puede trabajar con los primeros 5 componentes (57.1 % varianza) si se acepta cierta pérdida de fidelidad. Para modelos de recomendación o clasificación que requieran máxima precisión, se recomienda usar las 14 features originales directamente.

4 Agrupamiento (Clustering)

4.1 Justificación del Algoritmo: K-Means

Se seleccionó **K-Means** por las siguientes razones técnicas:

- El dataset tiene estructura numérica continua (10 features de audio estandarizadas), espacio donde K-Means opera eficientemente.
- Con 89,741 observaciones, *Agglomerative Clustering* sería inviable ($O(n^2)$ en memoria) y DBSCAN requiere calibración cuidadosa de ϵ en espacios de alta dimensión.
- El objetivo es obtener segmentos mutuamente excluyentes e interpretables para estrategia de negocio, no detectar outliers (DBSCAN) ni jerarquías (Agglomerative).
- K-Means es robusto, escalable y su resultado es directamente accionable: cada canción pertenece a un segmento bien definido.

4.2 Selección del Número de Clusters

Se evaluaron $k = 2, \dots, 8$ con dos criterios complementarios:

Table 8: Criterios de selección de k en K-Means

k	Inercia	Silhouette Score
2	42,100	0.298
3	35,800	0.231
4	31,200	0.201
5	28,400	0.185
6	26,300	0.172
7	24,800	0.162
8	23,600	0.153

Ambos criterios apuntan a $k = 2$: la inercia no muestra un codo pronunciado después de $k = 2$, y el Silhouette Score es máximo en $k = 2$ (0.298), indicando la mejor separación relativa entre clusters. Un score de 0.298 se interpreta como separación *moderada pero consistente*.

4.3 Perfil de los Clusters

Table 9: Características promedio por cluster

Feature	Cluster 0	Cluster 1
	<i>Energético/Bailable</i>	<i>Acústico/Instrumental</i>
Tamaño	67,499 (75.2 %)	22,242 (24.8 %)
Duration (min)	3.880	3.633
Danceability	0.596	0.460
Energy	0.746	0.295
Loudness (dB)	−6.490	−14.595
Speechiness	0.097	0.059
Acousticness	0.188	0.753
Instrumentalness	0.123	0.328
Liveness	0.229	0.182
Valence	0.523	0.307
Tempo (BPM)	126.3	109.3
Popularidad media	33.97	30.86

4.4 Visualización de Clusters




Figure 3: Proyección de los clusters en el espacio Energy–Acousticness (las dos features que mejor los separan). Los centroides se muestran con círculos dobles. La separación es clara: el Cluster 0 agrupa tracks de alta energía y baja acústica; el Cluster 1 agrupa el extremo opuesto.

4.5 Interpretación de Segmentos e Implicaciones Estratégicas

Cluster 0 — Energético/Bailable (75.2 % del catálogo): Agrupa el grueso del catálogo *mainstream*: canciones de alta energía (0.746), bailables (danceability = 0.596), con poca acústica y mayor valencia emocional (0.523). Tempo promedio de

126.3 BPM. Característico de Pop, Hip-Hop, Electronic y Dance. Popularidad media ligeramente superior (33.97).

Cluster 1 — Acústico/Instrumental (24.8 % del catálogo): Agrupa canciones de baja energía (0.295), alta acústica (0.753) y alto nivel de instrumentalidad (0.328). Menor valencia emocional (0.307) y tempo más lento (109.3 BPM). Representativo de Classical, Jazz, Folk Acoustic y Ambient. Popularidad media inferior (30.86).

Conclusión Ejecutiva

La partición en dos clusters refleja una división fundamental del catálogo de Spotify: música *mainstream/energética* vs. música *acústica/nicho*. Aplicaciones estratégicas directas: (1) Playlists de “Focus” y “Classical” deben alimentarse del Cluster 1; (2) el cluster puede usarse como filtro inicial en motores de recomendación antes de aplicar *collaborative filtering*; (3) el equipo de A&R puede identificar artistas del Cluster 1 con popularidad relativa alta (outliers positivos) como candidatos para crossover al mercado mainstream. La diferencia de popularidad media entre clusters es pequeña (3.1 puntos), lo que refuerza la idea de que la popularidad depende más de la promoción que del tipo de audio.

5 Clasificación con Red Neuronal

5.1 Formulación del Problema

Clasificación multiclase (3 clases): dado el vector de features de audio de una canción, predecir si su popularidad es **High** (> 60), **Medium** (30–60) o **Low** (< 30).

5.2 División Train / Validation / Test

Table 10: Particiones del dataset (estratificadas)

Partición	Proporción	Canciones	Propósito
Train	64 %	57,434	Ajuste de parámetros
Validation	16 %	14,358	Selección de hiperparámetros y early stopping
Test	20 %	17,949	Evaluación final (no vista durante entrenamiento)

La estratificación garantiza que las proporciones de las tres clases se preserven en cada partición, evitando sesgo por distribución desbalanceada.

5.3 Preprocesamiento

- Features numéricas (14): imputación de medianas + **StandardScaler**.
- Feature categórica (**track_genre**): imputación + One-Hot Encoding (113 géneros $\rightarrow$ 113 columnas binarias).
- Dimensión final del vector de entrada: **127 features**.
- Etiquetas: **LabelEncoder** $\rightarrow$ [0=High, 1=Low, 2=Medium].

5.4 Arquitectura del Modelo




Figure 4: Arquitectura del modelo ajustado (256→128→64). La reducción progresiva crea un cuello de botella que fuerza representaciones comprimidas y generalizables. Dropout(0.20) en cada capa actúa como regularización implícita.

5.5 Hiperparámetros y Mejoras Aplicadas

Table 11: Hiperparámetros del modelo ajustado

Hiperparámetro	Valor
Optimizador	AdamW
Learning rate	0.0008
Weight decay	10^{-5}
Función de pérdida	CrossEntropyLoss
Batch size	1,024
Épocas máximas	35
Early stopping (patience)	6 épocas
Dropout	0.20 (todas las capas)
Activación oculta	ReLU

Las mejoras aplicadas respecto al baseline (128→64, sin Batch Norm) son:

1. **Capa adicional** (256→128→64): mayor capacidad para 127 features.
2. **Early stopping** (patience = 6): detiene el entrenamiento cuando la pérdida de validación no mejora, previniendo sobreajuste.
3. **AdamW** (vs. Adam): la descorporación del weight decay mejora la generalización.
4. **Ajuste de learning rate** (0.001 → 0.0008): reduce oscilación cerca del mínimo.
5. **Batch size 1,024**: gradientes más estables en datasets grandes.
6. **Label smoothing** (explorado en tuning): suaviza distribuciones objetivo para mayor robustez ante etiquetas imprecisas.

5.6 Métricas de Desempeño

Table 12: Comparación de métricas: Baseline vs. Modelo Ajustado

Métrica	Baseline	Ajustado	Δ absoluto	Δ %
Accuracy (test)	0.6821	0.6917	+0.0096	+1.41 %
Precision (macro)	0.6804	0.6886	+0.0082	+1.21 %
Recall (macro)	0.6776	0.6884	+0.0108	+1.59 %
F1 Score (macro)	0.6758	0.6877	+0.0119	+1.76 %
Specificity (macro)	0.8405	0.8457	+0.0052	+0.62 %
Canciones mal clasificadas	5,708	5,534	−174	—
Val. Accuracy (mejor ép.)	0.6833	0.6863	+0.0030	—

5.7 Matriz de Confusión

	Pred. High	Pred. Low	Pred. Medium
Real High	4,241 (71.0 %)	768	965
Real Low	691	4,842 (76.5 %)	799
Real Medium	1,217	1,094	3,331 (59.0 %)

Figure 5: Matriz de confusión del modelo ajustado (test set = 17,949 canciones). Verde: predicciones correctas con recall por clase. Rojo: errores. El mayor error es Medium→High (1,217 canciones), reflejando la ambigüedad de la clase Media.

5.8 Análisis de Errores por Clase

Table 13: Desempeño por clase en el modelo ajustado

Clase	Total real	Correctas	Recall	Errores principales
High	5,974	4,241	71.0 %	→Medium: 965; →Low: 768
Low	6,332	4,842	76.5 %	→Medium: 799; →High: 691
Medium	5,643	3,331	59.0 %	→High: 1,217; →Low: 1,094

La clase **Medium** es la más difícil de clasificar (Recall = 59 %). Canciones con popularidad entre 30 y 60 son inherentemente ambiguas: sus features de audio no difieren sistemáticamente de los extremos. El modelo tiende a asignarlas a High o Low, sugiriendo que los límites de clase (30 y 60 puntos) son arbitrarios desde la perspectiva del espacio de audio.

5.9 Riesgo de Sobreajuste

- **Brecha train–test:** Accuracy train = 0.7320, test = 0.6917. Brecha = 0.0403 — pequeña y aceptable.
- El dropout (0.20) en cada capa y el early stopping (patience = 6) limitan efectivamente el sobreajuste.
- La brecha es ligeramente mayor en el modelo ajustado que en el baseline (0.0359 vs. 0.0403), indicando que la mayor capacidad introduce un leve sesgo hacia el conjunto de entrenamiento, pero sin comprometer la generalización.

Conclusión Ejecutiva

El modelo ajustado alcanza **69.17 % de accuracy** en clasificación triclase, con F1 macro = 0.6877 y especificidad = 0.8457. La especificidad alta indica que cuando el modelo predice una clase, incurre en pocos falsos positivos, lo que es valioso en producción. El principal reto es la clase Medium: una redefinición de umbrales con cuantiles del dataset (en lugar de 30/60 fijos) podría mejorar el desempeño. En producción, el modelo sería más valioso como clasificador binario High/No-High para priorizar tracks en listas de promoción editorial.

6 Conclusiones Estratégicas

6.1 Síntesis de Hallazgos

Table 14: Resumen ejecutivo de resultados por módulo

Módulo	Resultado clave	Limitación principal	Recomendación
Regresión	RMSE test = 15.9–16.8 pts. El género domina sobre el audio.	Features de audio insuficientes para alta precisión.	Incorporar datos de artista y contexto editorial.
PCA	11/14 componentes para 90 % varianza. Dataset poco comprensible.	Energía/Acústica dominan; emocionalidad es multidimensional.	5 PC para dashboards; 14 features para modelos.
Clustering	2 segmentos: Energético (75 %) y Acústico (25 %).	K-Means asume clusters esféricos; puede perderse sub-estructura.	Usar como filtro inicial en sistemas de recomendación.
Red Neuronal	Accuracy 69.2 %. Medium difícil (59 % recall).	Límites de clase arbitrarios. Sobreajuste leve (4 %).	Redefinir umbrales o usar clasificación binaria High/NoHigh.

6.2 Respuesta a la Pregunta de Negocio

¿Las características de audio predicen la popularidad en Spotify?

Respuesta: Parcialmente. Las features de audio tienen poder explicativo moderado ($\text{RMSE} \approx 16$ puntos, $\text{accuracy} \approx 69\%$), pero no son suficientes para predicciones de alta precisión. El género musical — proxy del contexto cultural y de mercado — tiene mayor impacto que cualquier feature de audio individual. El verdadero diferenciador de popularidad está fuera del audio: artista, playlists editoriales y marketing.

Este es un hallazgo valioso en sí mismo: le dice a Spotify que invertir exclusivamente en features de audio para predecir popularidad tiene rendimientos decrecientes. Los esfuerzos analíticos deberían dirigirse a capturar señales de red social, comportamiento del oyente y contexto editorial.

6.3 Próximos Pasos Recomendados

1. **Enriquecer el dataset** con variables de contexto: número de seguidores del artista, fecha de lanzamiento (temporada), presencia en playlists editoriales.
2. **Redefinir umbrales de clasificación** usando cuantiles del dataset en lugar de valores fijos (30/60), para clases más balanceadas y menos ambiguas.
3. **Explorar modelos híbridos** que combinen features de audio (PCA) con embeddings de artista para regresión/clasificación.
4. **Validar clustering con $k = 3-4$** para detectar sub-segmentos dentro del grupo Energético (e.g., separar Hip-Hop de EDM).
5. **Producción:** el clasificador puede desplegarse como microservicio que recibe features de audio y devuelve la probabilidad de popularidad Alta, útil para decisiones de ingesta de nuevo contenido.

Referencias

- [1] Pandya, M. (2023). *Spotify Tracks Dataset*. Kaggle. <https://www.kaggle.com/datasets/maharshipandya/-spotify-tracks-dataset>
- [2] Géron, A. (2022). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow* (3rd ed.). O'Reilly Media.
- [3] Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.
- [4] Jolliffe, I. T. (2002). *Principal Component Analysis* (2nd ed.). Springer.
- [5] MacQueen, J. (1967). Some methods for classification and analysis of multivariate observations. *Proceedings of the 5th Berkeley Symposium on Mathematical Statistics and Probability*, 1(14), 281–297.
- [6] Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- [7] Paszke, A., et al. (2019). PyTorch: An imperative style, high-performance deep learning library. *NeurIPS 2019*.